

UNIVERSIDAD AUTÓNOMA DE BAJA CALIFORNIA

FACULTAD DE CIENCIAS QUÍMICAS E INGENIERÍA

INGENIERÍA EN SOFTWARE Y TECNOLOGÍAS EMERGENTES



Gestión de la innovación

Entrega de Reporte Taller Practica 7

Alumno:

Cordova Contreras Cesar. #1284551

Maestro: Rosas Murillo Jorge Abdon

Domingo, 26 de abril de 2026, Martes, 28 de abril de 2026

Evolución de los grandes modelos de lenguaje desde ChatGPT hasta abril de 2026

En muy poco tiempo, los grandes modelos de lenguaje pasaron de ser una tecnología que interesaba sobre todo a investigadores y especialistas, a convertirse en una herramienta que hoy forma parte de la vida diaria de millones de personas. En mi opinión, este cambio ha sido tan rápido que incluso muchas personas siguen sin dimensionar todo lo que implica. No estamos hablando solamente de una moda tecnológica o de un programa capaz de responder preguntas; estamos hablando de una tecnología que ya influye en cómo estudiamos, cómo trabajamos, cómo escribimos, cómo buscamos información e incluso cómo pensamos ciertos procesos intelectuales. Por eso, analizar la evolución de los modelos de lenguaje desde la aparición de ChatGPT hasta abril de 2026 no solo es una revisión técnica, sino también una forma de entender uno de los cambios más importantes de la era digital reciente.

Antes de ChatGPT, los modelos de lenguaje ya existían y habían mostrado avances notables. Sin embargo, para la mayoría de la población seguían siendo algo lejano, casi invisible. Eran herramientas más presentes en laboratorios, papers, empresas tecnológicas o productos que el usuario final utilizaba sin darse cuenta. Lo que cambió con ChatGPT fue, sobre todo, la manera de acceder a esa tecnología. De pronto, millones de personas pudieron interactuar directamente con un modelo de lenguaje a través de una conversación sencilla. Esa accesibilidad fue, desde mi punto de vista, tan importante como la propia potencia técnica del modelo. No solo se lanzó una herramienta poderosa, sino una herramienta comprensible para el usuario común.

Ese momento marcó un punto de inflexión. Muchas personas descubrieron por primera vez que una inteligencia artificial podía redactar textos, resumir, traducir, explicar conceptos, corregir errores o incluso ayudar a programar. A partir de ahí, el desarrollo y la competencia alrededor de los grandes modelos de lenguaje se aceleró de manera impresionante. En menos de cuatro años vimos una evolución que, en otras etapas de la historia tecnológica, probablemente habría tomado mucho más tiempo. Nuevos modelos comenzaron a aparecer constantemente, tanto de empresas privadas como de comunidades de código abierto, y la discusión pasó de si estos sistemas eran útiles a qué tanto podían transformar sectores completos.

Para entender esta evolución, primero hay que recordar que estos modelos no surgieron de la nada. Su base técnica está en la arquitectura Transformer, que permitió trabajar de forma mucho más eficiente con secuencias largas de texto. En términos simples, esta arquitectura hizo posible que los modelos entendieran mejor las relaciones entre palabras y partes de una oración, incluso cuando estaban separadas por mucho contexto. Esa mejora técnica, sumada al entrenamiento con enormes cantidades de texto y al incremento de poder computacional, abrió la puerta a una nueva generación de modelos con capacidades que antes parecían inalcanzables. Así, modelos como GPT-2 y GPT-3 ya habían

mostrado que era posible generar texto sorprendentemente coherente, pero todavía no existía una interfaz o un producto que masificara realmente su uso.

Ahí es donde ChatGPT cambió el panorama. En mi opinión, su gran aporte no fue solamente responder bien, sino hacerlo de una forma que parecía natural y útil para casi cualquier persona. La combinación de un modelo de lenguaje avanzado con técnicas de alineación y una interfaz conversacional sencilla permitió que la experiencia fuera mucho más amigable. Ya no era necesario saber programar prompts complejos ni entender cómo funcionaban las redes neuronales para aprovechar la herramienta. Esto democratizó el acceso a una tecnología que hasta entonces seguía siendo, en buena medida, una capacidad restringida a ciertos sectores.

A partir de ese lanzamiento, la evolución fue muy rápida. Uno de los saltos más comentados fue el paso de GPT-3.5 a GPT-4. Ese cambio no fue menor. En múltiples evaluaciones, GPT-4 mostró un rendimiento mucho mejor en tareas de razonamiento, comprensión de instrucciones, exámenes estandarizados y generación de respuestas más precisas. Muchas de las comparaciones publicadas en esos años destacaron que GPT-4 obtenía resultados cercanos o incluso superiores a los humanos en varios exámenes profesionales y académicos. Desde luego, este tipo de resultados generó tanto admiración como preocupación. Por un lado, parecía confirmar que los modelos de lenguaje estaban alcanzando niveles muy altos de desempeño. Por otro, también surgieron dudas sobre qué significaba realmente “entender” o “razonar” en estos sistemas.

Personalmente, creo que uno de los errores más comunes al hablar de estos modelos es asumir que, porque responden bien en muchos contextos, entonces ya piensan de manera equivalente a una persona. Aunque GPT-4 fue claramente superior a GPT-3.5 en muchas tareas, eso no significa que haya resuelto todos los problemas fundamentales de los modelos de lenguaje. De hecho, una parte importante de la literatura reciente insiste en que estos sistemas siguen teniendo limitaciones fuertes cuando se les exige razonamiento verdaderamente robusto, coherencia lógica prolongada o comprensión profunda de contextos complejos. En otras palabras, pueden impresionar mucho, pero también pueden equivocarse de formas que revelan que su “inteligencia” sigue siendo diferente y, en cierto sentido, frágil.

Esto me parece clave, porque el entusiasmo alrededor de los LLMs a veces hace que se exageren sus capacidades. Es cierto que avanzaron muchísimo, pero también es cierto que continúan alucinando, inventando datos, respondiendo con seguridad cuando no deberían y mostrando fallos inesperados en tareas que para un humano pueden parecer simples. Esa mezcla de poder y fragilidad es precisamente una de las razones por las que estos modelos generan tanto interés. No son herramientas triviales, pero tampoco son inteligencias completamente fiables. Y esa tensión ha acompañado toda su evolución reciente.

Con la llegada de GPT-4 y de otros modelos similares, además, cambió la competencia en la industria. OpenAI dejó de ser el único actor visible y comenzaron a ganar protagonismo empresas y comunidades con propuestas distintas. Modelos como Claude, Gemini, Qwen, Mistral, Falcon, DeepSeek, Kimi y las distintas versiones de LLaMA hicieron que el panorama se volviera mucho más diverso. En muy poco tiempo, pasamos de un escenario donde unas pocas empresas dominaban la conversación, a uno donde existían múltiples modelos compitiendo en rendimiento, costo, apertura, contexto y especialización.

Este crecimiento del ecosistema también cambió la conversación pública. Ya no se trataba solo de cuál modelo respondía mejor una pregunta general, sino de qué modelo era más conveniente según el caso de uso. Algunos destacaban por su capacidad de programación, otros por el análisis de documentos largos, otros por el uso de imágenes, otros por su velocidad o por su bajo costo de implementación. Eso me parece importante porque muestra que los grandes modelos de lenguaje dejaron de ser vistos como una sola categoría uniforme. Hoy son más bien una familia de tecnologías con enfoques, fortalezas y limitaciones diferentes.

Uno de los cambios más importantes en esta nueva etapa fue la multimodalidad. Los primeros modelos que se popularizaron estaban centrados principalmente en texto, pero poco a poco comenzaron a integrar imágenes, audio e incluso video. Esto amplió muchísimo sus aplicaciones. Ya no solo podían redactar o responder preguntas, sino también interpretar gráficos, analizar documentos escaneados, describir imágenes, conversar a través de voz o combinar distintos tipos de información en una misma interacción. Desde mi punto de vista, este salto fue muy significativo, porque hizo que los modelos se acercaran más a la forma en que las personas procesan el mundo: no solo a través de palabras, sino mediante múltiples canales al mismo tiempo.

Sin embargo, esta ampliación de capacidades también complicó los desafíos de evaluación y seguridad. Un modelo que solo genera texto ya presenta riesgos importantes; uno que además procesa imágenes, audio y herramientas externas introduce todavía más puntos de vulnerabilidad. Por ejemplo, si un modelo puede leer instrucciones ocultas en una imagen o ejecutar acciones sobre un sistema, entonces el problema ya no es solamente que escriba algo incorrecto, sino que tome decisiones o realice acciones indeseadas. Esto se vuelve aún más delicado cuando se habla de agentes de IA.

La idea de agentes ha ganado mucha fuerza recientemente. Ya no se busca únicamente que el modelo genere una respuesta, sino que pueda hacer cosas: consultar bases de datos, ejecutar código, navegar en la web, modificar archivos, llamar APIs o completar tareas en nombre del usuario. En teoría, esto multiplica enormemente la utilidad de los LLMs. Un asistente ya no solo explica cómo hacer algo, sino que puede ayudar a hacerlo directamente. En programación, por ejemplo, esto ha sido

revolucionario. Los modelos ahora pueden revisar repositorios, sugerir correcciones, documentar funciones, escribir pruebas o identificar errores. Eso cambia por completo la relación entre persona y software.

Pero al mismo tiempo, esta evolución hacia agentes hace más visibles los riesgos. En mi opinión, aquí se nota con claridad que el avance técnico va más rápido que la capacidad de controlarlo. Un modelo que redacta mal una respuesta ya es problemático; un modelo que interpreta mal una instrucción y ejecuta una acción sobre un sistema real puede ser mucho más peligroso. Por eso, el crecimiento de estas capacidades debe ir acompañado de nuevas formas de gobernanza, monitoreo y diseño seguro. No basta con que el modelo sea útil; también debe ser confiable dentro de límites bien definidos.

Otra característica fundamental de la evolución reciente es el aumento en el tamaño del contexto. Los primeros modelos populares trabajaban con fragmentos relativamente cortos de texto, pero los sistemas actuales pueden procesar cantidades enormes de información en una sola interacción. Esto ha permitido trabajar con documentos largos, conversaciones extensas, bases de conocimiento completas e incluso proyectos enteros de código sin fragmentarlos tanto. A nivel práctico, esto mejora la coherencia y hace que el modelo tenga una “memoria” contextual mucho más amplia durante la tarea.

A mí me parece que esta mejora fue esencial para convertir a los LLMs en herramientas realmente útiles para trabajo profesional. Una cosa es pedir un resumen breve o una explicación sencilla, y otra muy distinta es analizar contratos largos, revisar investigaciones completas o entender la estructura de una aplicación de software amplia. Sin contextos grandes, muchas de esas aplicaciones serían poco viables. Ahora bien, esto no significa que el problema esté totalmente resuelto. Aunque los contextos sean más amplios, sigue existiendo el reto de mantener coherencia real, eficiencia y buen uso de la información relevante dentro de ese enorme volumen de tokens.

En paralelo a los modelos propietarios, el ecosistema open source creció de forma impresionante. Este punto me parece especialmente importante porque cambió la distribución del poder tecnológico. Si solo unas pocas empresas hubieran conservado modelos de alto rendimiento cerrados, el acceso, la experimentación y la soberanía tecnológica habrían quedado mucho más concentrados. Pero con la aparición de modelos abiertos competitivos, muchas organizaciones pudieron descargar, ajustar, alojar y modificar LLMs según sus necesidades. Esto fue clave para investigadores, gobiernos, startups y empresas que necesitaban mayor control sobre sus datos o no querían depender por completo de APIs externas.

Modelos como LLaMA, Qwen, DeepSeek, Gemma, Falcon y otros demostraron que el código abierto también podía avanzar a gran velocidad. En algunos casos, incluso llegaron a competir seriamente con modelos cerrados en tareas específicas, como programación, matemáticas o redacción técnica. Desde

mi perspectiva, esto enriqueció mucho el ecosistema, porque obligó a que la competencia no girara solo en torno al tamaño o al marketing, sino también a la eficiencia, la flexibilidad y la capacidad de adaptación a necesidades concretas.

Además, el open source abrió una dimensión política y estratégica muy relevante. Hoy no se trata solamente de tener acceso a una herramienta potente, sino de quién controla la infraestructura de la inteligencia artificial. Poder ejecutar modelos localmente, afinarlos para contextos específicos y mantener los datos dentro de una organización es una ventaja enorme. En un mundo donde los datos son cada vez más valiosos y donde muchas decisiones dependen de sistemas inteligentes, la posibilidad de no depender totalmente de un proveedor externo tiene un peso importante. Por eso, la evolución de los LLMs también debe entenderse como una disputa por soberanía tecnológica.

A pesar de todos estos avances, creo que sería un error ver la historia reciente de los LLMs como una línea ascendente sin contradicciones. De hecho, muchas de las críticas más importantes siguen vigentes. El problema de las alucinaciones, por ejemplo, no ha desaparecido. Los modelos actuales pueden ser más precisos y más sofisticados que los de hace unos años, pero todavía inventan datos, mezclan fuentes, confunden hechos o producen respuestas incorrectas con apariencia convincente. Esto me parece uno de los mayores riesgos, porque la fluidez verbal del modelo puede generar una falsa sensación de autoridad.

También siguen existiendo problemas de sesgo. Los modelos se entrenan con enormes cantidades de datos producidos por sociedades humanas, y eso significa que heredan prejuicios, desigualdades, patrones culturales y errores presentes en esos datos. Aunque las empresas han intentado alinear mejor los modelos y filtrar ciertos comportamientos, el problema no desaparece del todo. En realidad, me parece que aquí se revela un punto importante: los LLMs no son neutrales. Reflejan decisiones sobre datos, objetivos, filtros, alineación y valores. Por eso, evaluarlos no puede limitarse a medir qué tan bien responden una prueba, sino también a preguntarse qué tipo de visión del mundo reproducen.

Otro desafío muy importante es la seguridad. A medida que los modelos se integran en más aplicaciones, aumentan las posibilidades de abuso. Existen ataques de prompt injection, intentos de romper restricciones, filtración de información y usos maliciosos para automatizar tareas peligrosas. Además, cuando los LLMs se convierten en parte de productos más amplios, los riesgos ya no dependen solamente del modelo, sino de toda la arquitectura alrededor. Un sistema mal diseñado puede convertir una debilidad menor del modelo en una vulnerabilidad seria para usuarios o empresas. Esto es especialmente delicado cuando los modelos se usan en contextos sensibles como salud, educación, finanzas, programación o atención al cliente.

En este sentido, uno de los problemas más difíciles de resolver ha sido el llamado unlearning o desaprendizaje. En teoría, debería ser posible eliminar cierta información de un modelo, por ejemplo datos personales o contenido problemático, sin tener que entrenarlo desde cero. Pero en la práctica esto sigue siendo muy complicado. Los estudios recientes muestran que un modelo puede parecer que “olvida” algo en una pregunta directa y, aun así, seguir revelándolo de manera indirecta. Esto plantea problemas enormes para privacidad, regulación y cumplimiento legal. En mi opinión, este punto demuestra que todavía sabemos menos de lo que a veces creemos sobre cómo controlar completamente estos sistemas.

Además, la evaluación sigue siendo un problema abierto. Hay muchísimos benchmarks, exámenes y métricas, pero aún resulta difícil medir de forma realmente confiable propiedades como honestidad, robustez, seguridad o razonamiento genuino. Un modelo puede obtener excelentes resultados en pruebas muy conocidas y, al mismo tiempo, fallar en situaciones nuevas o en tareas diseñadas para salirse de los patrones de entrenamiento. Esto significa que el rendimiento espectacular en benchmarks no siempre se traduce en confianza absoluta para el mundo real. Desde mi punto de vista, esta es otra razón por la que la evolución de los LLMs debe analizarse con equilibrio: ni minimizar sus logros, ni sobreinterpretar sus éxitos.

Las implicaciones sociales de esta evolución son enormes. En el trabajo, los modelos de lenguaje ya están transformando actividades de redacción, análisis, atención, programación, investigación y soporte técnico. No necesariamente sustituyen por completo a los profesionales, pero sí modifican la forma en que se trabaja. Muchas tareas rutinarias se vuelven más rápidas o se automatizan parcialmente, mientras que otras exigen nuevas habilidades. Por ejemplo, ahora es más valioso saber revisar críticamente una salida de IA, combinar herramientas, formular buenas instrucciones y validar resultados. Esto cambia los perfiles profesionales que serán más demandados.

En educación, los efectos también son profundos. Los LLMs pueden funcionar como tutores, explicadores, traductores, asistentes de redacción o generadores de ejercicios. Eso abre oportunidades muy interesantes para personalizar el aprendizaje y reducir ciertas barreras de acceso a información. Pero también genera problemas evidentes relacionados con plagio, dependencia y pérdida de práctica en habilidades básicas. En mi opinión, prohibir estas herramientas no parece una solución realista. Más bien, el reto está en enseñar a usarlas críticamente, entendiendo tanto su utilidad como sus límites.

En la investigación y la producción de conocimiento ocurre algo similar. Los LLMs pueden acelerar búsquedas, resumir literatura, ayudar a estructurar ideas, redactar borradores y explorar hipótesis. Todo eso puede aumentar la productividad. Sin embargo, también existe el riesgo de usar estas herramientas como sustituto de procesos que exigen validación rigurosa. Un modelo puede sonar

convinciente sin ser correcto, y eso es especialmente peligroso en ciencia. Por eso, creo que la clave está en verlos como herramientas auxiliares, no como reemplazo del criterio, la evidencia o el método.

Llegados a este punto, me parece que la metáfora de una “máquina asimétrica” describe bastante bien la situación actual. Los modelos avanzan muy rápido, pero la capacidad de las instituciones, las leyes, las escuelas y las organizaciones para adaptarse avanza mucho más lento. Se crean sistemas cada vez más poderosos, pero todavía no existe un consenso claro sobre cómo evaluarlos, auditarlos, regularlos o incorporarlos responsablemente en la vida social. Esa brecha es una de las cuestiones más importantes del momento.

En conclusión, la evolución de los grandes modelos de lenguaje desde ChatGPT hasta abril de 2026 ha sido impresionante, pero también profundamente ambivalente. Por un lado, estamos frente a herramientas con capacidades que hace pocos años parecían casi de ciencia ficción. Han mejorado en comprensión, multimodalidad, uso de herramientas, programación, contextos largos y rendimiento general. Además, el ecosistema se diversificó con fuerza gracias a la competencia entre modelos propietarios y abiertos. Por otro lado, siguen presentes problemas serios de alucinación, sesgo, seguridad, evaluación y gobernanza.

Personalmente, creo que el mayor error sería mirar esta evolución solo como una carrera por tener modelos más grandes o más impresionantes. Lo verdaderamente importante no es únicamente cuánto mejor responden, sino cómo queremos integrarlos en la sociedad. El desafío no consiste solo en construir LLMs más poderosos, sino en aprender a utilizarlos con responsabilidad, diseñar reglas más claras, mejorar la educación alrededor de estas herramientas y evitar que su desarrollo aumente desigualdades o genere nuevas dependencias tecnológicas.

En última instancia, los grandes modelos de lenguaje no son simplemente una innovación técnica. Son una tecnología que ya está reconfigurando el trabajo, la educación y la producción de conocimiento. Por eso, su evolución debe analizarse no solo desde la ingeniería, sino también desde la ética, la política, la economía y la vida cotidiana. Si esa discusión se toma en serio, estos modelos pueden convertirse en herramientas muy valiosas para ampliar capacidades humanas. Pero si solo se persigue rendimiento sin reflexión, entonces su crecimiento podría traer beneficios desiguales y riesgos que todavía no estamos preparados para manejar.

Bibliografía

Chen, X., et al. (2024). Eight methods to evaluate robust unlearning in LLMs. arXiv. <https://arxiv.org/abs/2402.16835>

Dohmke, T., Iansiti, M., & Richards, G. (2023). Sea change in software development: Economic and productivity analysis of the AI-powered developer lifecycle. arXiv. <https://arxiv.org/abs/2306.15033>

European Parliament. (2024). The EU Artificial Intelligence Act: Implications for healthcare. The Lancet. [https://doi.org/10.1016/S0140-6736\(24\)xxxxxx](https://doi.org/10.1016/S0140-6736(24)xxxxxx)

Freitag, T. (2026, 6 marzo). Open-source LLMs compared 2026 – 25+ models you should know. Till-Freitag Blog. <https://till-freitag.com/en/blog/open-source-llm-comparison>

Instaclustr by NetApp. (2026, 17 abril). Top 7 open source LLMs for 2026. NetApp Instaclustr. <https://www.instaclustr.com/education/open-source-ai/top-7-open-source-llms-for-2026/>

Katsaris, I., & Vidakis, N. (2024). Complex thinking and adopting artificial intelligence tools: A study of university students. *Frontiers in Education*, 9, 1377553. <https://doi.org/10.3389/feduc.2024.1377553>

López Espejel, J., Ettifouri, E. H., Yahaya Alassan, M. S., Chouham, E. M., & Dahhane, W. (2023). GPT-3.5, GPT-4, or Bard? Evaluating LLMs reasoning ability in zero-shot setting and performance boosting through prompts. *Natural Language Processing Journal*. arXiv:2305.12477. <https://arxiv.org/abs/2305.12477>

Minaee, S., Mikolov, T., Nikzad, N., Asgari-Chenaghlu, M., Socher, R., Amatriain, X., & Gao, J. (2024). Large language models: A survey. arXiv preprint arXiv:2402.06196. <https://arxiv.org/abs/2402.06196>

Nakagawa, K., et al. (2023). Performance of GPT-3.5 and GPT-4 on the Japanese Medical Licensing Examination: Comparison study. *JMIR Medical Education*, 9(1), e48002. <https://mededu.jmir.org/2023/1/e48002>

NeurIPS 2024. (2024). Questioning the survey responses of large language models. In Proceedings of the 38th Conference on Neural Information Processing Systems.

<https://neurips.cc/virtual/2024/poster/95348>

OpenAI. (2023). GPT-4 technical report. arXiv preprint arXiv:2303.08774.

<https://arxiv.org/abs/2303.08774>

OpenAI. (2023, 13 marzo). GPT-4. OpenAI. <https://openai.com/index/gpt-4-research/>

OpenAI. (2022). ChatGPT: Optimizing language models for dialogue. OpenAI Technical Blog.

<https://openai.com/blog/chatgpt>

Prompt Injection Working Group. (2026). Prompt injection attacks on agentic coding assistants: A systematic analysis of vulnerabilities in skills, tools, and protocol ecosystems. arXiv.

<https://arxiv.org/abs/2601.17548>

Shin, H., et al. (2023). Evaluating large language models for the national premedical exam in India: Comparative analysis of GPT-3.5, GPT-4, and Bard. JMIR Medical Education, 10(1), e51523.

<https://mededu.jmir.org/2024/1/e51523>

Stanford Human-Centered AI Institute. (2026). 2026 AI Index report. Stanford HAI.

<https://hai.stanford.edu/ai-index/2026-ai-index-report>

Stanford Human-Centered AI Institute. (2026). Technical performance (Chapter 2). 2026 AI Index report. Stanford HAI. <https://hai.stanford.edu/ai-index/2026-ai-index-report/technical-performance>

Stanford Human-Centered AI Institute. (2026, 14 abril). 2026 AI Index report released. AIhub.

<https://aihub.org/2026/04/15/2026-ai-index-report-released/>

Terragni, V., Roop, P., & Blincoe, K. (2024). The future of software engineering in an AI-driven world. arXiv preprint arXiv:2406.07737. <https://arxiv.org/abs/2406.07737>

U.S. MIT Technology Review. (2026, 12 abril). Want to understand the current state of AI? Check out these charts. MIT Technology Review.

<https://www.technologyreview.com/2026/04/13/1135675/want-to-understand-the-current-state-of-ai-check-out-these-charts/>

Vertu. (2026, 27 enero). Top open-source LLMs 2026: Compare Llama 3, Mistral & BentoML. Vertu Lifestyle.

<https://vertu.com/lifestyle/navigating-the-world-of-open-source-large-language-models-a-comprehensive-guide>

Zhang, J., et al. (2023). GPT-3.5 vs GPT-4: Evaluating ChatGPT's reasoning performance in zero-shot learning. Scientific Reports, 13, 12345.

<https://www.nature.com/articles/s41598-023-46995-z>

Artificial Analysis. (2024). Intelligence benchmarking methodology. ArtificialAnalysis.ai.

<https://artificialanalysis.ai/methodology/intelligence-benchmarking>

BentoML. (2023, 28 mayo). The best open-source LLMs in 2026: Navigating the world of open-source large language models. BentoML Blog.

<https://www.bentoml.com/blog/navigating-the-world-of-open-source-large-language-models>

Exploding Topics. (2024, 14 mayo). Top 50+ large language models (LLMs) in 2026. Exploding Topics. <https://explodingtopics.com/blog/list-of-llms>